

Анализ данных Барометра Центральной Азии

Ryan Womack

2026-03-31

Copyright Ryan Womack, 2026. Данная работа распространяется под лицензией [CC BY-NC-SA 4.0](#)

Анализ данных Барометра Центральной Азии

Обработка данных, разведочный анализ данных и визуализация данных Центральноазиатского Барометра.

первоначально разработано для презентации на [Американский Университет Центральной Азии](#), Весна 2026

[Обратите внимание: русский текст переведен с английского с помощью машинного перевода]

1 Обзор

Этот семинар посвящен работе с данными, начиная с основ импорта и подготовки данных и заканчивая описательной статистикой, базовым анализом и визуализацией данных. Программирование ведется преимущественно на языке R, но также используются некоторые примеры на Python. И R, и Python — отличные инструменты для анализа данных, поэтому в некоторой степени ваш выбор зависит от предпочтений и уровня знакомства с языком. Язык R возник из области статистики и дополнил ее вычислительными функциями, в то время как Python — это универсальный язык программирования, к которому были добавлены значительные возможности статистического анализа.

1.1 Определения

Статистика — это широкая область, предоставляющая строгие инструменты для анализа данных с помощью математики. Хотя мы можем рассматривать *машинное обучение* как тему информатики, фундаментальная теория машинного обучения в основном основана на статистике. Машинное обучение (ML) относится ко многим возможным методам использования вычислительных ресурсов на основе математических моделей для понимания данных и прогнозирования на их основе. *Искусственный интеллект* (AI)

также является частью машинного обучения, и до роста популярности *генеративного AI* (Generative AI) AI/ML обычно обозначали широкий набор аналитических методов. Генеративный AI (GenAI) в более узком смысле относится к ИИ, который делает вероятностные предположения на основе больших объемов обучающих данных, обычно используя *большие языковые модели* (LLM). Поскольку GenAI не обеспечивает воспроизводимых результатов, он не так полезен для получения надежных результатов исследований. *Vibe coding*, программирование с использованием GenAI, или разработка компьютерного кода и синтаксиса, может иметь некоторые применения, но его сложно использовать без базового понимания соответствующих языков программирования. В случае текущих проектов, требующих постоянных изменений в расширяющейся кодовой базе, GenAI хуже справляется с созданием кода, который не меняет структуру проекта.

2 Установка

Данный семинар *не* охватывает установку R и RStudio, но предполагает наличие у вас рабочей копии этих программ.

R — это программное обеспечение с открытым исходным кодом для статистического анализа, доступное по адресу [R-project.org](https://www.R-project.org). Рекомендуется сначала установить R. Команды R можно выполнять во многих редакторах и IDE, непосредственно в терминале или через скриптовые файлы. Однако один из самых мощных и распространенных методов, который мы будем использовать здесь, — это использование IDE RStudio.

RStudio, доступный на [Posit](https://posit.co/) в виде [загрузки с открытым исходным кодом](#), — это инструмент для создания и запуска кода на языке R (а также на Python и нескольких других языках), обладающий множеством полезных функций и шаблонов для работы с другими форматами и инструментами в экосистеме R. RStudio будет использовать установленную вами версию R, работая как надстройка над ней. Posit также разрабатывает [Positron](#) — более новую IDE с большей гибкостью для работы с R, Python и другими возможными языками. В этом мастер-классе не используется Positron, хотя код должен работать и там.

И RStudio, и Positron внедряют в свои интерфейсы инструменты подсказок на основе искусственного интеллекта, которые, как утверждается, работают с конкретным кодом вашего проекта и понимают его. Их следует предпочитать использованию сторонних сервисов, таких как ChatGPT.

Для немедленного использования без установки попробуйте следующее:

- [Posit Cloud](#) — это также бесплатный сервис, позволяющий использовать RStudio (с некоторыми ограничениями по времени и памяти) после создания учетной записи.

Более подробную информацию можно найти в видеоролике [Начало работы с R](#) (или в других веб-уроках и руководствах).

[Python](#) также является языком с открытым исходным кодом и может использоваться с различными редакторами и инструментами, которые здесь не описаны подробно.

2.1 R помощь

Система справки R легкодоступна. Используйте вопросительный знак перед именем конкретной функции, чтобы открыть ее страницу руководства (*?sample* или *?rnorm*). Используйте два вопросительных знака для поиска. Вкладка «Справка» в правом нижнем углу RStudio также предоставляет полный доступ к встроенной справке, включая руководства и поиск.

Поиск в интернете справки по R может быть полезен, поскольку существует множество руководств, статей в блогах и других материалов по общим методам и конкретным пакетам R. Полезно добавить к поисковому запросу что-то вроде «статистика R», «программное обеспечение R» или «пакет R», чтобы отличать его от всех других случаев использования буквы R!

3 Настройка и подготовка данных

3.1 Необходимые пакеты R

Для установки мы будем использовать пакет *pak*, поскольку это более полный подход к управлению пакетами. При желании замените команды *pkg* на версии, созданные с помощью *install.packages()*.

В этом занятии предпочтительно используется набор пакетов *tidyverse* для обработки данных, хотя те же задачи можно выполнить в базовом R с помощью других функций. Установите *pak* и *tidyverse*, если они еще не установлены в вашей системе. Нам также понадобится *reticulate* для запуска фрагментов кода Python.

```
install.packages("pak", dependencies=TRUE)
library(pak)
pkg_install("tidyverse")
pkg_install("readxl")
pkg_install("reticulate")
devtools::session_info()
```

Обратите внимание, что команду *update.packages()* можно периодически запускать для проверки наличия более новых версий установленных пакетов.

Загрузите пакеты, чтобы мы могли с ними работать.

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.0      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.2      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.1
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

3.2 Версии

Ссылки справа предоставляют альтернативные способы доступа к этому контенту. Вы можете выбрать светлый или темный режим HTML, загрузить PDF-файл или файл Word в формате Docx — все они будут содержать один и тот же контент. Также доступны файлы кода на языке R (.R) или Python (.py), если вы хотите отделить код от описания.

3.3 Кыргызский и русский языки

Кроме того, справа приведены ссылки на машинный перевод этого контента на русский и киргизский языки.

3.4 поддержка Python

Теперь загрузим *reticulate* (только для поддержки Python). Необходимо указать правильное местоположение Python, соответствующее нашей системе.

Для тех, кто хочет попробовать выполнить те же шаги обработки данных на Python, предоставляется файл Python. Обратите внимание, что файл Python был переведен машинным способом из R.

```
# Sys.setenv(RETICULATE_PYTHON = "/usr/bin/python3")
library(reticulate)
use_python("/usr/bin/python3")
```

4 Барометр Центральной Азии

Как вам, вероятно, известно, проект [Барометр Центральной Азии](#) проводит опросы и исследования в странах Центральной Азии (Казахстан, Кыргызстан, Таджикистан, Туркменистан и Узбекистан) и регулярно публикует результаты. За исключением последней волны данных, данные Барометра Центральной Азии можно бесплатно скачать с их веб-сайта, указав контактный адрес электронной почты. Эти опросы изучают современные политические и социальные взгляды и позволяют проводить долгосрочные сравнения, а также межстрановые сравнения.

На этом первом семинаре мы познакомимся с Барометром Центральной Азии, рассмотрев последние данные (2022 год) по одной стране (Кыргызстан). Второй семинар расширит и углубит наше понимание, добавив к анализу дополнительные годы и страны, а также изучив более сложные методы обработки и анализа данных.

4.1 Понимание данных

Прежде чем заниматься программированием или статистическим анализом, первым шагом в работе с реальными данными является понимание их структуры и смысла. Нам нужно знать, какие данные были собраны, как они организованы, и подумать, на какие вопросы они могут ответить. Только тогда мы сможем понять, как правильно приступить к их анализу.

Для CA Barometer это означает изучение [Анкеты \(для опроса 2022 года\)](#) и [Отчета о методах](#) за этот год.

5 Загрузка и импорт данных

Мы загружаем данные из [Центральноазиатского барометра](#) по адресу <https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-kyrgyzstan-kyrgyzstan-2022-autumn.xlsx>

```
download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-kyrgyzstan-kyrgyzstan-2022-autumn.xlsx", "CAB_2022.csv")
mydata <- read_excel("CAB_2022.csv")
mydata
```

```
# A tibble: 1,518 x 158
      MM1 MM2b MM3a MM3b MM4      MM5 MM6      MM7 MM8
    <dbl> <dbl> <dbl> <chr> <chr>    <dbl> <chr>    <dbl> <dtm>
1 100017  778     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
2 100028  771     6 CATI  Kyrgyzstan  163 Female  1 2022-11-01 00:00:00
3 100035  505     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
4 100036  509     6 CATI  Kyrgyzstan  311 Female  1 2022-11-01 00:00:00
5 100048  706     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
6 100054  504     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
7 100085  502     6 CATI  Kyrgyzstan  210 Female  1 2022-11-01 00:00:00
8 100086  708     6 CATI  Kyrgyzstan  251 Female  1 2022-11-01 00:00:00
9 100087  500     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
10 100099  553     6 CATI  Kyrgyzstan  329 Female  1 2022-11-01 00:00:00
# i 1,508 more rows
# i 149 more variables: MM9 <dtm>, MM10 <chr>, MM11 <chr>, MM12 <dtm>,
# MM13 <dtm>, MM14 <chr>, A1a <chr>, A1b <chr>, A2 <chr>, A3a <chr>,
# A3b <chr>, A4a <chr>, A4b <chr>, A4c <chr>, A4d <chr>, A4e <chr>,
# A4f <chr>, A5a <chr>, A5b <chr>, A5c <chr>, A5d <chr>, A6 <chr>, A7 <chr>,
# B1 <chr>, B2 <chr>, B3 <chr>, B4a <chr>, B4b <chr>, B5a <chr>, B5b <chr>,
# B6a <chr>, B6b <chr>, B6c <chr>, B6d <chr>, B6e <chr>, B7 <chr>, ...
```

```
attach(mydata)
```

6 Обработка данных

6.1 Выбор и наименование

Для анализа мы выберем интересные переменные из анкеты. Также мы изменим их названия на более запоминающиеся.

Мы хотим провести исследование по нескольким параметрам:

- язык, регион, доход, пол

и связать это с мнениями. Мы можем потратить некоторое время на изучение анкеты, чтобы увидеть, как обозначены эти переменные.

Обратите внимание, что MM4 — это код страны, но мы уже загрузили файл по Киргизии, поэтому нам не нужно явно его выбирать. Также обратите внимание, что этническая группа уже обозначена как «EthnicGrp». Доступ к другим переменным мы сделаем более интуитивно понятным, переименовав их.

`names(mydata)`

```
[1] "MM1"      "MM2b"     "MM3a"     "MM3b"     "MM4"      "MM5"
[7] "MM6"      "MM7"      "MM8"      "MM9"      "MM10"     "MM11"
[13] "MM12"     "MM13"     "MM14"     "A1a"      "A1b"      "A2"
[19] "A3a"      "A3b"      "A4a"      "A4b"      "A4c"      "A4d"
[25] "A4e"      "A4f"      "A5a"      "A5b"      "A5c"      "A5d"
[31] "A6"       "A7"       "B1"       "B2"       "B3"       "B4a"
[37] "B4b"      "B5a"      "B5b"      "B6a"      "B6b"      "B6c"
[43] "B6d"      "B6e"      "B7"       "B8"       "B9a"      "B9b"
[49] "B9c"      "B9d"      "B10"      "B11a"     "B11b"     "B12"
[55] "B13"      "B14"      "B15a"     "B15b"     "B15c"     "B15d"
[61] "B16"      "D1"       "D2a"      "D2b"      "E1a"      "E1b"
[67] "E1c"      "E1d"      "E1e"      "E2a"      "E2b"      "E2c"
[73] "E2d"      "E2e"      "E3"       "E4a"      "E4b"      "E5a"
[79] "E5b"      "E5c"      "E6a"      "E6b"      "E7a"      "E7b"
[85] "E7c"      "E8a"      "E8b"      "E8c"      "E8d"      "E8e"
[91] "E9a"      "E9b"      "E10"      "E11"      "E12"      "E13"
[97] "E14"      "E15a"     "E15b"     "E15c"     "E16"      "E17"
[103] "E19a"     "E19b"     "E19c"     "E20a"     "E20b"     "E20c"
[109] "E21"      "G1a"      "G1b"      "G2"       "G3a"      "G3b"
[115] "G4"       "G5"       "G6"       "G7"       "G8"       "G9"
[121] "H1"       "H2"       "H3"       "H4"       "H5a"      "H5b"
[127] "DD1"      "DD2"      "DD3"      "DD4"      "DD5"      "DD6a"
[133] "DD6b"     "DD6c"     "DD7a"     "DD7b"     "DD7c"     "DD8"
[139] "DD9a"     "DD9b"     "DD9c"     "DD9d"     "DD10"     "DD11"
[145] "DD12"     "DD13"     "DD14"     "DD15"     "DD16"     "DD17"
[151] "DD18a"    "DD18b"    "DD19"     "DD20"     "EthnicGrp" "AgeGrp"
[157] "FinalWgt1" "FinalWgt2"
```

```
mydata <- mydata |> rename('Sex'='DD1', 'Region'='MM10',
  ↳ 'Language'='DD11', 'Income'='DD8')
attach(mydata)
```

The following objects are masked from mydata (pos = 3):

```
A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b,
A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a,
B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c,
B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12,
DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3,
DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c,
DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a,
E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a,
E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a,
E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1,
FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2,
H3, H4, H5a, H5b, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b,
MM4, MM5, MM6, MM7, MM8, MM9
```

6.2 Описательная статистика

Давайте рассмотрим несколько из этих переменных и посмотрим, как они распределены. Простая команда *table* поможет вам получить первоначальное представление о данных. Хотя некоторые большие наборы данных сложно интуитивно понять, для такого рода данных в социальных науках нет ничего лучше, чем потратить время на изучение данных, прежде чем переходить к более сложному анализу. Мы также можем обнаружить выбросы или проблемы, которые необходимо исправить, прежде чем двигаться дальше.

```
table(Sex)
```

```
Sex
Female   Male
    750    768
```

```
table(Region)
```

```
Region
Batzenskaja      Bishkek      Chujskaja Dzhahal-Abadskaja
      105           399           228           222
Issyk-Kul'skaja  Narynskaja      Osh City      Oshskaja
      142           83           65           214
Talaskaja
      60
```

```
table(Language)
```

Language			
Don't Know (vol.)	Kazakh	Kyrgyz	Other (vol.)
2	1	1280	14
Refused (vol.)	Russian	Tajik	Turkmen
1	154	1	2
Uzbek			
63			

`table(Income)`

Income		
10,001 - 12,000 som	12,001 - 16,000 som	16,001 - 20,000 som
71	136	160
2,801 - 4,100 som	20,001 - 28,000 som	4,101 - 6,000 som
33	185	46
6,001 - 8,000 som	8,001 - 10,000 som	Don't Know (vol.)
36	96	84
Less than 2,801 som	More than 28,000 som	Refused (vol.)
40	570	61

`table(EthnicGrp)`

EthnicGrp			
Kyrgyz	Other Russian	Uzbek	
1315	62	63	78

`table(Sex, Language)`

Language						
Sex	Don't Know (vol.)	Kazakh	Kyrgyz	Other (vol.)	Refused (vol.)	Russian
Female	1	0	627	5	1	92
Male	1	1	653	9	0	62

Language			
Sex	Tajik	Turkmen	Uzbek
Female	1	1	22
Male	0	1	41

`table(Income, Sex)`

Income	Sex	
	Female	Male
10,001 - 12,000 som	36	35
12,001 - 16,000 som	71	65
16,001 - 20,000 som	84	76
2,801 - 4,100 som	17	16
20,001 - 28,000 som	95	90
4,101 - 6,000 som	30	16
6,001 - 8,000 som	21	15

8,001 - 10,000 som	56	40
Don't Know (vol.)	49	35
Less than 2,801 som	17	23
More than 28,000 som	251	319
Refused (vol.)	23	38

```
table(E17)
```

```
E17
```

A few more months	A few more weeks	About another week	Another month
333	21	27	65
Another year	Don't know (vol.)	More than a year	Refused (vol.)
279	373	209	16
Several more days	Two years or more		
32	163		

6.3 Перекодирование данных

Одна из обнаруженных проблем заключается в том, что доход отображается по категориям, в виде диапазонов. Если мы хотим рассматривать доход как число, нам придется его перекодировать. В приведенном ниже коде мы устанавливаем для каждого диапазона приблизительное среднее значение, используя команду *recode_values*.

```
mydata$Income_Numeric <- recode_values(
  Income,
  "Less than 2,801 som" ~ 1400,
  "2,801 - 4,100 som" ~ 3400,
  "4,101 - 6,000 som" ~ 5000,
  "6,001 - 8,000 som" ~ 7000,
  "8,001 - 10,000 som" ~ 9000,
  "10,001 - 12,000 som" ~ 11000,
  "12,001 - 16,000 som" ~ 14000,
  "16,001 - 20,000 som" ~ 18000,
  "20,001 - 28,000 som" ~ 24000,
  "More than 28,000 som" ~ 40000,
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)
```

Мы повторно подключаем данные, чтобы убедиться, что новая переменная *Income_Numeric* легкодоступна, а затем проверяем, как всё получилось.

```
attach(mydata)
```

The following objects are masked from mydata (pos = 3):

```
A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b,
A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a,
B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c,
```

B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12, DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c, DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a, E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a, E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1, FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2, H3, H4, H5a, H5b, Income, Language, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9, Region, Sex


The following objects are masked from mydata (pos = 4):

A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a, B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12, DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c, DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a, E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a, E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1, FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2, H3, H4, H5a, H5b, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9

```
mean(Income_Numeric, na.rm=TRUE)
```

```
[1] 24995.78
```

```
hist(Income_Numeric)
```



```
mydata |>
group_by(Sex) |>
summarize(Inc = mean(Income_Numeric, na.rm=TRUE))
```

```
# A tibble: 2 x 2
  Sex      Inc
  <chr>   <dbl>
1 Female 23753.
2 Male   26208.
```

```
# t-tests or chi-sq for significance
```

```
# try a t-test
```

```
# is income significantly different by sex - yes
```

```
t.test(Income_Numeric~Sex)
```

Welch Two Sample t-test

data: Income_Numeric by Sex

t = -3.3228, df = 1370.6, p-value = 0.0009147

alternative hypothesis: true difference in means between group Female and group Male is not eq

95 percent confidence interval:

-3904.313 -1005.607

sample estimates:

mean in group Female mean in group Male

23753.10

26208.06

7 Графики - Визуализация данных

Мы можем выбрать любую общую тему для обсуждения, например, какое приложение для обмена сообщениями используют люди. На самом деле, в Кыргызстане все пользуются WhatsApp, так что, возможно, это не так интересно! Давайте выберем что-нибудь более общее, например, движется ли страна в правильном или неправильном направлении.

```
table(Sex,A3a)
```

```

      A3a
Sex    Do not use chat rooms or messengers Don't Know (vol.) Other (vol.)
Female                16                2                1
Male                  22                1                7
```

```

      A3a
Sex    Telegram Viber WhatsApp
Female      41      0      690
Male       52      1      685
```

`table(D1)`

D1

Don't Know (vol.)	Refused (vol.)	Right direction	Wrong direction
138	16	1157	207

`table(D1, Sex)`

	Sex	
D1	Female	Male
Don't Know (vol.)	72	66
Refused (vol.)	9	7
Right direction	579	578
Wrong direction	90	117

`table(D1, Region)`

	Region			
D1	Batkenskaja	Bishkek	Chujskaja	Dzhalal-Abadskaja
Don't Know (vol.)	5	40	22	19
Refused (vol.)	1	2	5	3
Right direction	90	266	162	181
Wrong direction	9	91	39	19

	Region				
D1	Issyk-Kul'skaja	Narynskaja	Osh City	Oshskaja	Talaskaja
Don't Know (vol.)	6	8	8	18	12
Refused (vol.)	3	0	0	2	0
Right direction	125	69	53	173	38
Wrong direction	8	6	4	21	10

`table(D1, Language)`

	Language				
D1	Don't Know (vol.)	Kazakh	Kyrgyz	Other (vol.)	Refused (vol.)
Don't Know (vol.)	1	0	112	1	0
Refused (vol.)	0	0	10	0	1
Right direction	1	1	1009	11	0
Wrong direction	0	0	149	2	0

	Language			
D1	Russian	Tajik	Turkmen	Uzbek
Don't Know (vol.)	20	0	0	4
Refused (vol.)	4	0	0	1
Right direction	79	1	2	53
Wrong direction	51	0	0	5

`table(D1, Income_Numeric)`

	Income_Numeric									
D1	1400	3400	5000	7000	9000	11000	14000	18000	24000	40000
Don't Know (vol.)	3	1	3	2	11	6	7	17	15	50
Refused (vol.)	0	2	0	0	1	1	2	0	1	7
Right direction	31	26	38	30	78	56	115	125	147	414
Wrong direction	6	4	5	4	6	8	12	18	22	99

Измените код, удалив слова «Не знаю» и «Отказано».

```
mydata$D1_recode <- recode_values(
  D1,
  "Right direction" ~ "Right",
  "Wrong direction" ~ "Wrong",
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)

mydata$D1_recode <- as.factor(mydata$D1_recode)

attach(mydata)
```

The following objects are masked from mydata (pos = 3):

A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a, B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12, DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c, DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a, E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a, E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1, FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2, H3, H4, H5a, H5b, Income, Income_Numeric, Language, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9, Region, Sex

The following objects are masked from mydata (pos = 4):

A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a, B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12, DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c, DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a, E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a, E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a,

E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1, FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2, H3, H4, H5a, H5b, Income, Language, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9, Region, Sex

The following objects are masked from mydata (pos = 5):

A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, AgeGrp, B1, B10, B11a, B11b, B12, B13, B14, B15a, B15b, B15c, B15d, B16, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, D1, D2a, D2b, DD10, DD12, DD13, DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD2, DD20, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b, DD7c, DD9a, DD9b, DD9c, DD9d, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a, E19b, E19c, E1a, E1b, E1c, E1d, E1e, E20a, E20b, E20c, E21, E2a, E2b, E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b, E8c, E8d, E8e, E9a, E9b, EthnicGrp, FinalWgt1, FinalWgt2, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, G8, G9, H1, H2, H3, H4, H5a, H5b, MM1, MM11, MM12, MM13, MM14, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9


7.1 Иллюстративные графики

Вот несколько наглядных графиков. На данном этапе мы не стремимся сделать их красивыми, а просто хотим быстро понять наши данные.

```
# Some illustrative plots
```


```
ggplot(data=mydata, aes(x=Income_Numeric, y=Region))+geom_point()
```

Warning: Removed 145 rows containing missing values or values outside the scale range (`geom\_point()`).




```
ggplot(data=mydata, aes(x=Region, y=Income_Numeric))+geom_jitter()
```

Warning: Removed 145 rows containing missing values or values outside the scale range (`geom\_point()`).




```
boxplot(Income_Numeric~D1)
```




D1

`boxplot(Income_Numeric~D1_recode)`



D1_recode

`ggplot(mydata, aes(x=D1_recode))+facet_grid(~Sex)+geom_bar()`



8 Дальнейший статистический анализ

8.1 Логистическая регрессия

В качестве примера статистического анализа можно попробовать использовать логистическую регрессию для прогнозирования правильного ответа на вопрос о направлении движения. Логистическая регрессия — подходящий метод, когда результат представляет собой бинарный выбор (да/нет, верно/неверно, правильно/неверно).

```
logistic_output <- glm(D1_recode ~ Sex + Language + Income_Numeric,
  ↪ family=binomial, data=mydata)
summary(logistic_output)
```

Call:

```
glm(formula = D1_recode ~ Sex + Language + Income_Numeric, family = binomial,
  data = mydata)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.504e+01	8.827e+02	-0.017	0.98641
SexMale	3.881e-01	1.688e-01	2.298	0.02154 *
LanguageKazakh	-2.200e-01	1.248e+03	0.000	0.99986
LanguageKyrgyz	1.246e+01	8.827e+02	0.014	0.98874
LanguageOther (vol.)	1.258e+01	8.827e+02	0.014	0.98863
LanguageRussian	1.390e+01	8.827e+02	0.016	0.98744
LanguageTajik	6.654e-02	1.248e+03	0.000	0.99996
LanguageTurkmen	-4.101e-01	1.080e+03	0.000	0.99970

```

LanguageUzbek      1.178e+01  8.827e+02  0.013  0.98935
Income_Numeric     1.692e-05  6.179e-06  2.739  0.00617 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 1042.64  on 1243  degrees of freedom
Residual deviance: 983.01  on 1234  degrees of freedom
(274 observations deleted due to missingness)
AIC: 1003

```

Number of Fisher Scoring iterations: 13

9 Другие возможности

Это лишь некоторые заметки о дополнительных интересных переменных в данных, хотя вы можете выбрать свои собственные и изучить их подробнее.

Вопрос B13 — «Эмигрируют ли русские в ваш регион?» — можно проанализировать по регионам.

Вопрос E17 — «Как долго продлится конфликт с Украиной?» — задан в 2022 году.

Вопрос G3b — «Отношение к президенту Жапарову?» — какие аспекты были бы интересны для анализа?

10 Заключение

В анализе данных нет единой точки остановки. Продолжайте, пока не получите полное понимание данных и их взаимодействия с вопросами, на которые вы пытаетесь ответить. Во второй части этой серии семинаров, [Барометр Центральной Азии 2](#), будут рассмотрены более сложные методы и комбинации данных.

Дополнительные сведения о методах анализа данных см. в разделах [Анализ данных 1](#) и [Анализ данных 2](#).

10.1 R для анализа данных [книга *R for Data Science*]

Для получения дополнительной информации об обработке данных обратитесь к книге «R for Data Science» (<https://r4ds.hadley.nz/>). Также ознакомьтесь с пакетом `tidymodels` (<https://www.tidymodels.org/>), предназначенным для моделирования и машинного обучения с использованием принципов `tidyverse`.